Entendiendo los p-values

Estadística aplicada a bioinformática · sesión de 40 minutos

Comparamos colon sano con tumor colorrectal y un gen se expresa más en el tumor.

¿Basta esa diferencia para decir que el gen está asociado con la enfermedad?

LOS DATOS DE HOY

Un dataset real de GEO: GSE9348

Tejido	Mucosa de colon
Grupos	12 controles sanos · 70 tumores (CRC estadio temprano)
Plataforma	GPL570 — Affymetrix HG-U133 Plus 2.0 (~54 000 sondas)
Diseño	Muestras independientes (no pareadas)
Archivo	GSE9348_series_matrix.txt.gz → carpeta de Drive del curso
En clase	Tomamos 8 sanas y 8 enfermas al azar (se puede cambiar en el script)

Todo el análisis usa solo R base: no hay que instalar paquetes.

4–11 MIN

Formular la pregunta antes de mirar el resultado

H_0 · hipótesis nula

No hay diferencia en la expresión media del gen entre sano y enfermo.

H_1 · hipótesis alternativa

Sí hay diferencia entre los grupos (en cualquier dirección → bilateral).

- Estadístico: un resumen de la evidencia (aquí, diferencia de medias)
- Distribución nula: qué valores serían habituales si H_0 fuera cierta
- La dirección (uni/bilateral) se decide antes, no después de ver los datos

DEFINICIÓN

¿Qué es un p-value?

La probabilidad, suponiendo que H_0 y los supuestos del modelo son correctos,

de obtener un estadístico tan extremo como el observado, o más.

NO es...

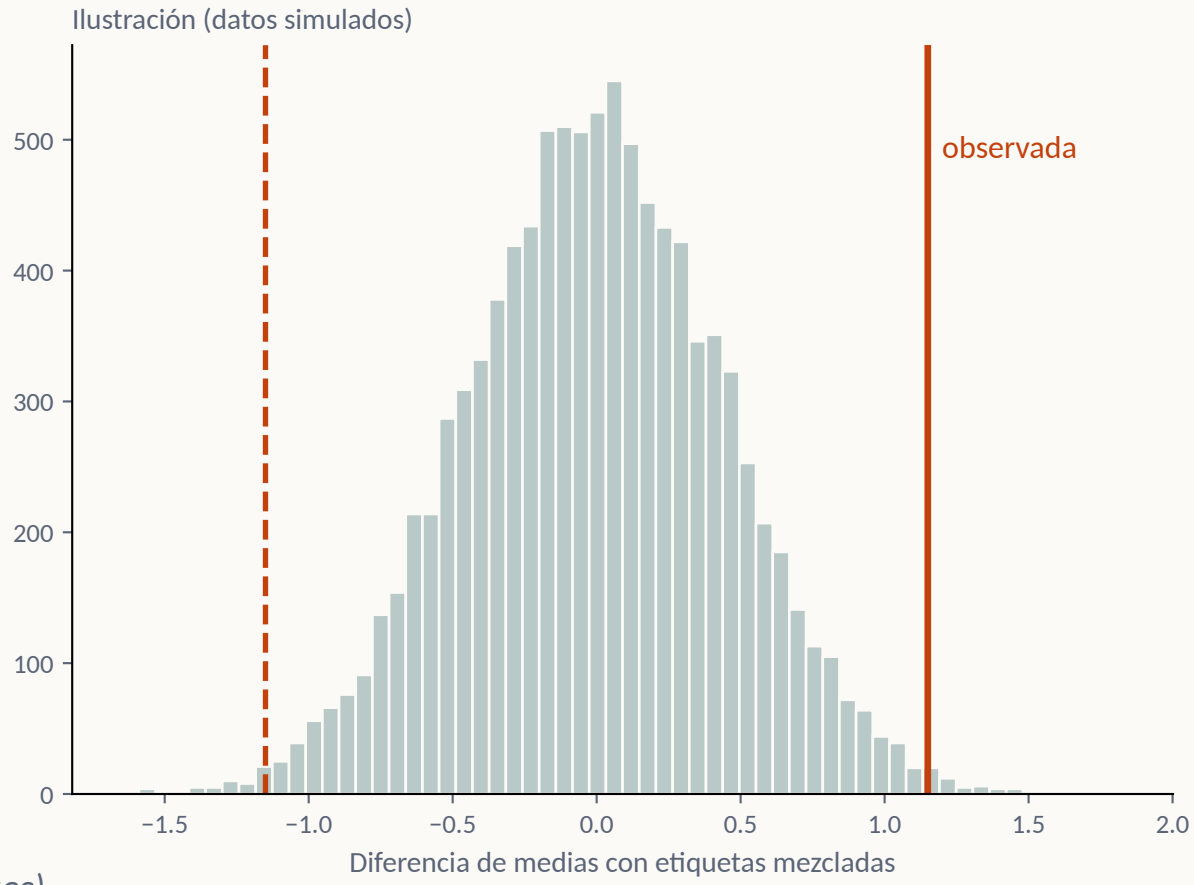
- × la probabilidad de que H_0 sea verdadera
- × la probabilidad de que el resultado “se deba al azar ”
- × una medida del tamaño del efecto
- × una frontera mágica: p = 0.049 ≈ p = 0.051

Pregunta al grupo: ¿p = 0.01 significa 99 % de probabilidad de que H_0 sea falsa?

11–20 MIN · EN R

Construir la distribución nula mezclando etiquetas

1. Calcula la diferencia observada (Enfermo − Sano)
2. Mezcla las etiquetas sano/enfermo manteniendo fijos los valores
3. Recalcula la diferencia; repite B = 9 999 veces
4. p = (b + 1) / (B + 1)
   b = permutaciones al menos tan extremas



Ojo: solo vale si las etiquetas son intercambiables (no pareadas, sin bloques).

20–29 MIN

Un gen frente a 54 000 sondas

Si todas las H_0 fueran ciertas:

20 000 × 0.05 ≈ 1 000

resultados con p < 0.05 esperados por azar

- En el script: mezclamos las etiquetas
- y aun así salen cientos de p < 0.05
- Con BH, casi ninguno sobrevive

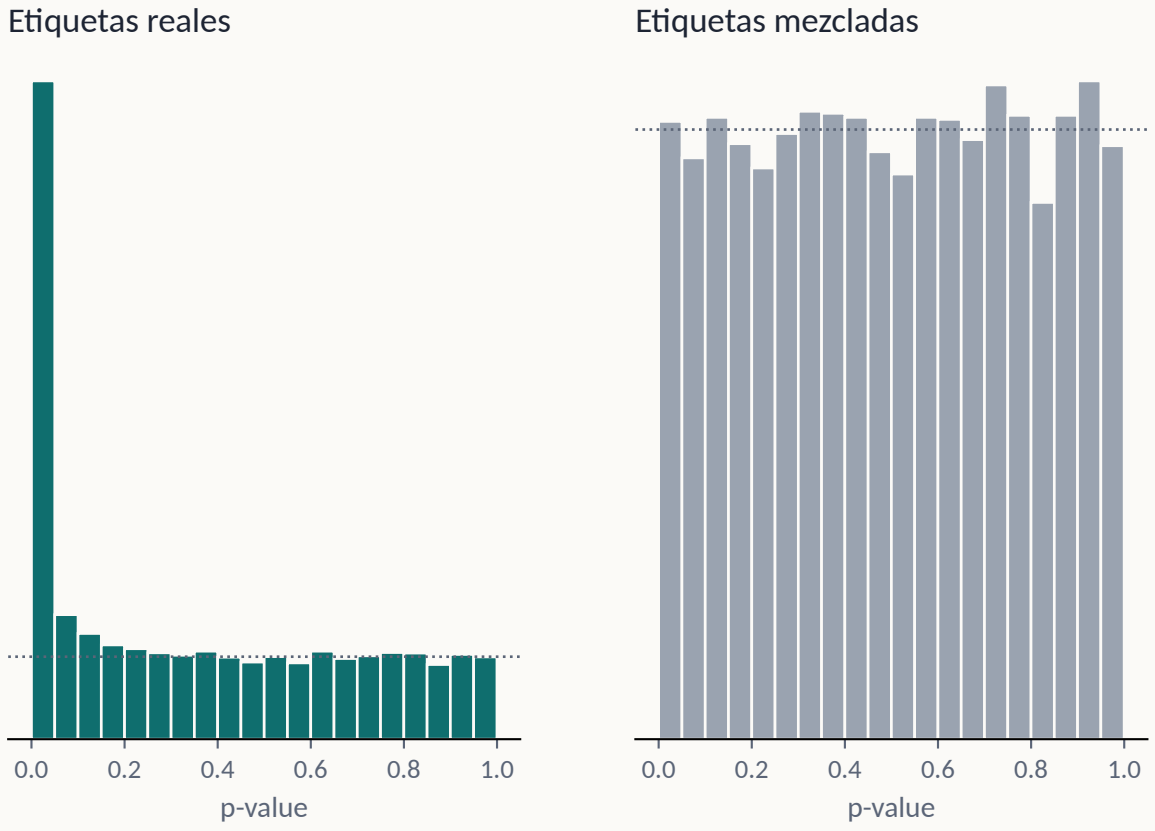


Ilustración (datos simulados)

Bonferroni frente a Benjamini–Hochberg

Bonferroni

Controla la probabilidad de
≥ 1 falso positivo (FWER)

Umbral: α / m
0.05 / 20 000 = 2.5×10^{-6}

Muy estricto: pierde
efectos reales

```
p.adjust(p, method = "bonferroni")
```

Benjamini–Hochberg (FDR)

Controla la proporción esperada
de falsos descubrimientos

Habitual en análisis exploratorios
de expresión génica

FDR ≤ 0.05 no significa 5 % para
cada gen concreto

```
p.adjust(p, method = "BH")
```

Ajustar p-values no arregla un mal diseño, sesgos ni supuestos incumplidos.

29–35 MIN

Leer una tabla de resultados

Gen	p sin ajustar	FDR (BH)	¿FDR < 0.05?
Gen A	0.001	0.02	**Sí**
Gen B	0.03	0.18	**No**
Gen C	0.20	0.40	**No**

Gen B: parece significativo solo, pero no supera el criterio al considerar todas las pruebas.

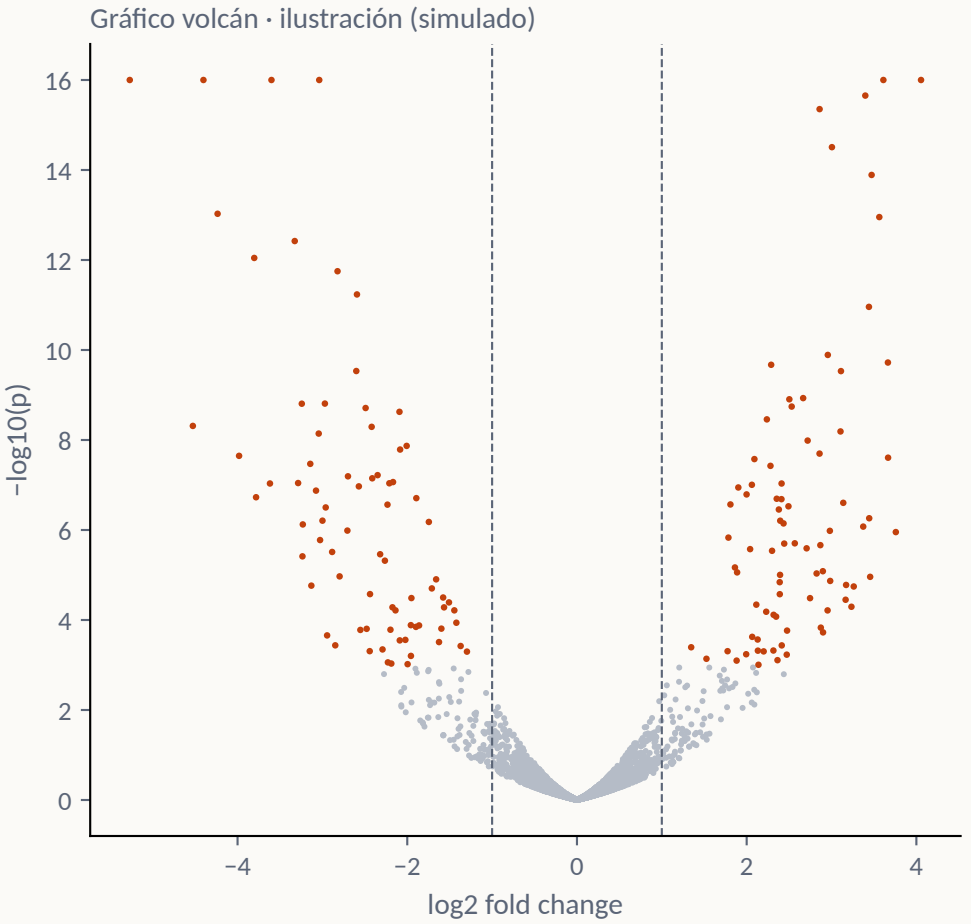
Valores didácticos. El script genera la tabla real con log2FC, p, FDR y Bonferroni.

Pregunta al grupo: Si un gen tiene FDR < 0.05, ¿ya es un buen biomarcador?

INTERPRETAR

Estadísticamente significativo ≠ biológicamente relevante

- Un efecto pequeño puede dar p muy bajo con muchas muestras
- Un efecto grande puede no ser significativo con pocas muestras
- Mira siempre el tamaño del efecto (log2FC)
- Un biomarcador exige validación independiente
- y experimentos funcionales o clínicos



35–40 MIN · CIERRE

Cinco ideas para llevarse

1. El p-value se calcula suponiendo H_0 y unos supuestos
2. No es la probabilidad de que H_0 sea cierta ni el tamaño del efecto
3. Permutar etiquetas construye la distribución nula (si el diseño lo permite)
4. Con miles de pruebas hay que corregir: Bonferroni (FWER) o BH (FDR)
5. Significancia ≠ relevancia biológica, causalidad ni utilidad clínica

¿Qué hipótesis y supuestos hay detrás de este p-value, cuántas pruebas se hicieron y qué evidencia adicional necesito?

MATERIAL

Para repetirlo en casa

GitHub	entendiendo_pvalues.R · diapositivas.pdf · temario.md · README.md
Drive	GSE9348_series_matrix.txt.gz (guardar en la carpeta datos/)
Requisitos	R y RStudio. Sin paquetes adicionales.
Ejercicios	Al final del script: cambiar n por grupo, la semilla y la sonda

¿Dudas?